


# IAA-2023c1

## Clase 2: ML End to End & Regresión Lineal

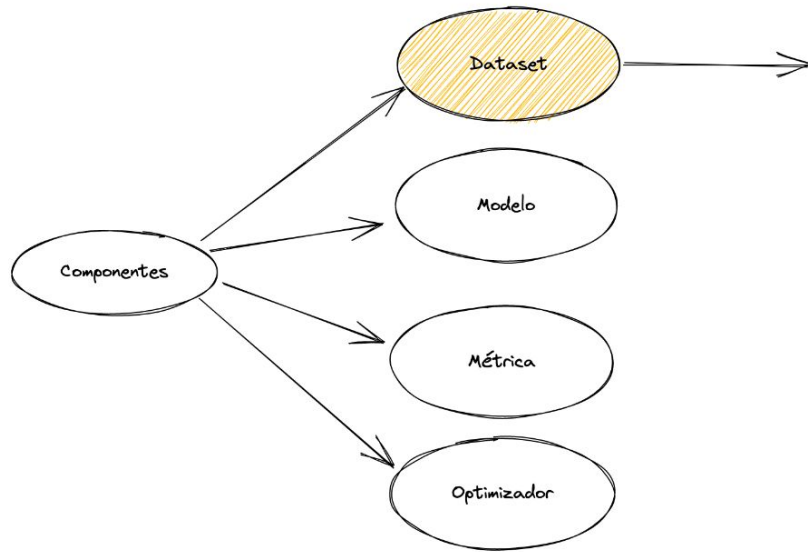


**UNSAM**  
UNIVERSIDAD  
NACIONAL DE  
SAN MARTÍN


# Repaso: Componentes



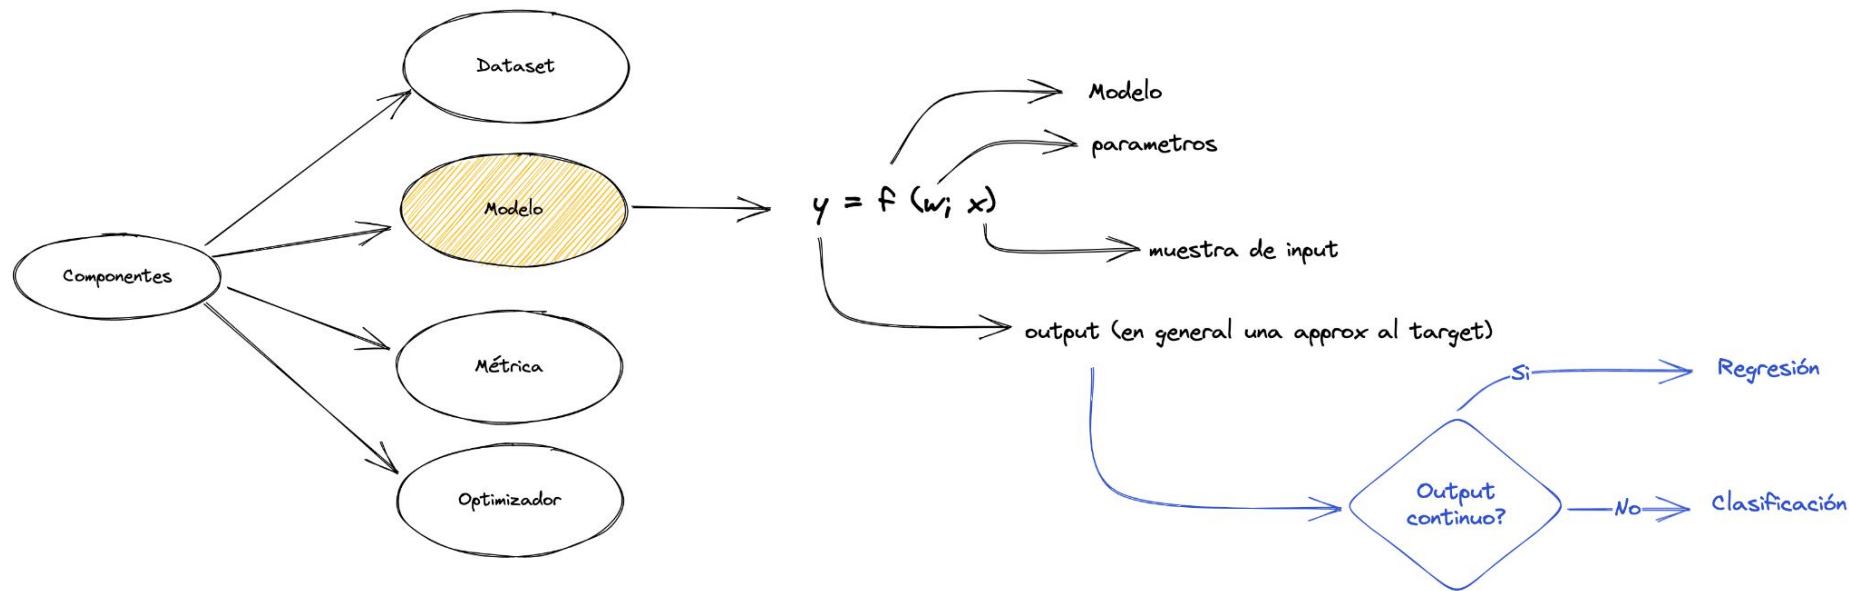
# Repaso: Supervisado vs No Supervisado



|           | feature 1          | feature 2 | ... | feature M | target |
|-----------|--------------------|-----------|-----|-----------|--------|
| muestra 1 | "Matriz de diseño" |           |     |           |        |
| muestra 2 |                    |           |     |           |        |
| muestra 3 |                    |           |     |           |        |
| ...       |                    |           |     |           |        |
| muestra N |                    |           |     |           |        |



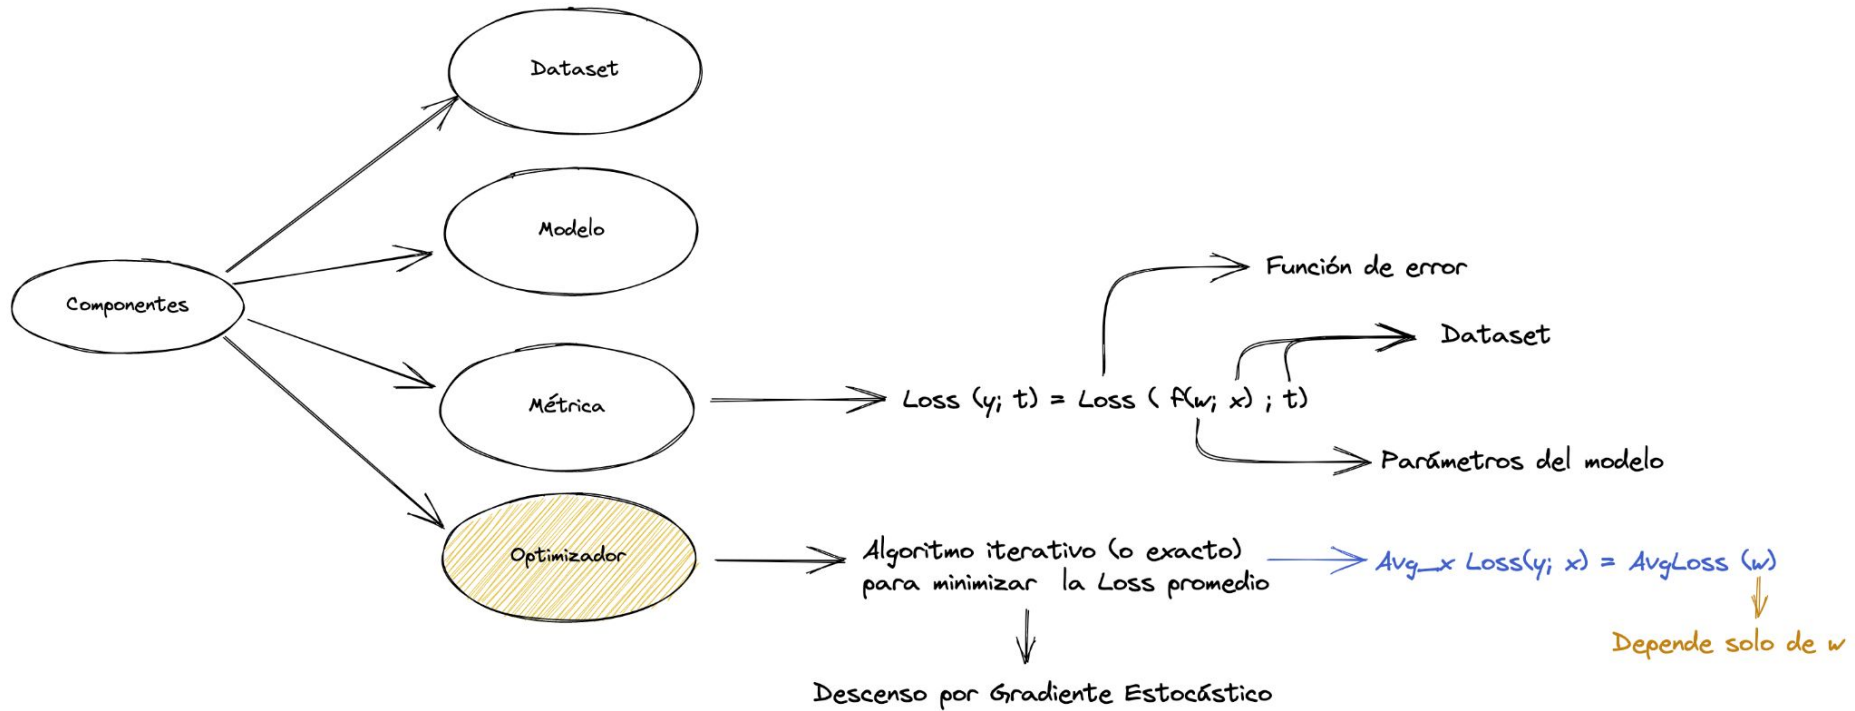
# Repaso: Regresión vs Clasificación



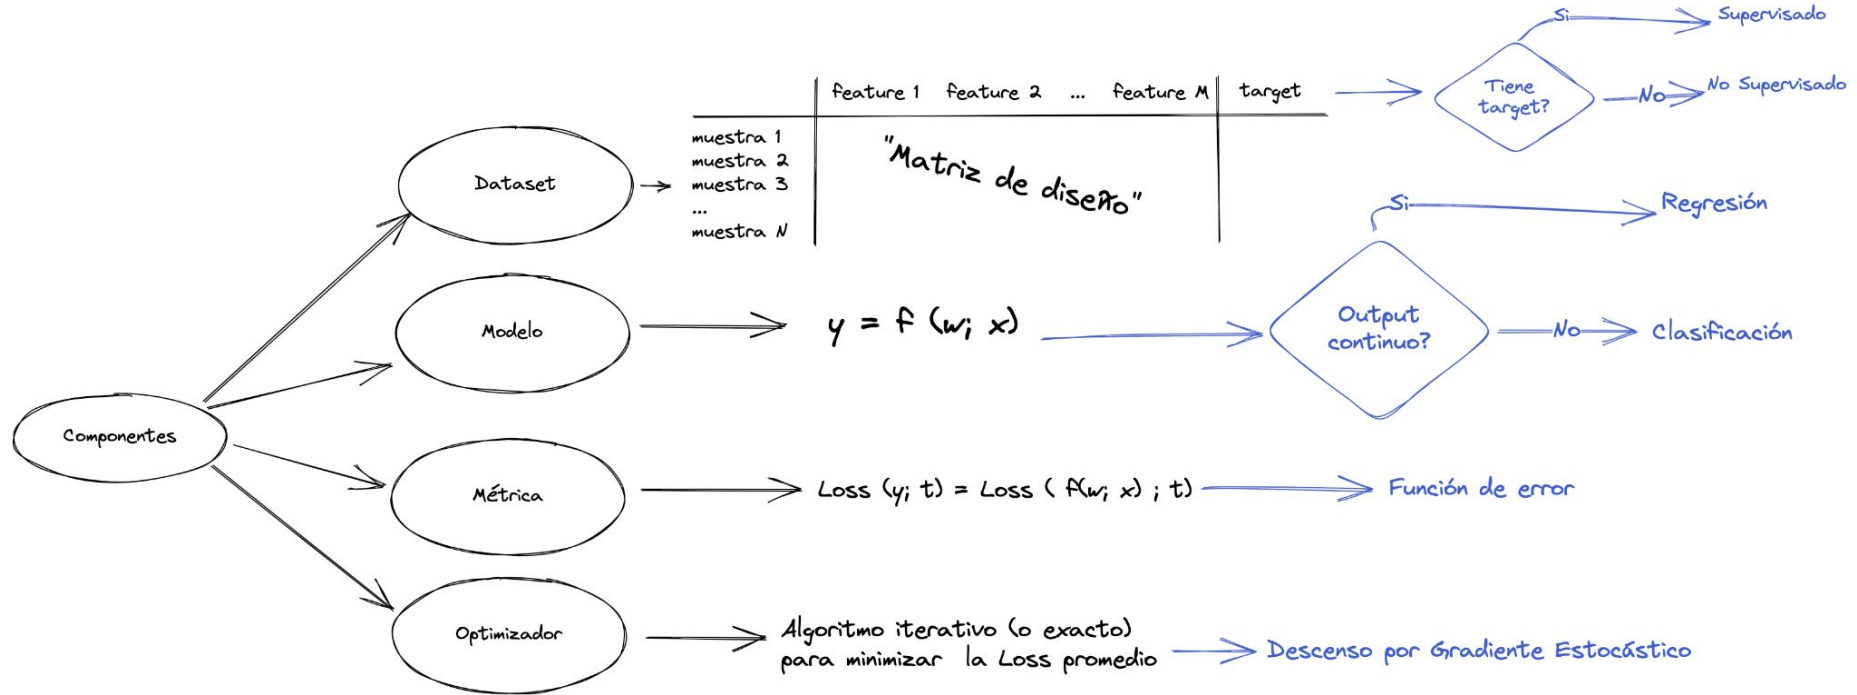
# Repaso: Métrica y Función de Error / Pérdida



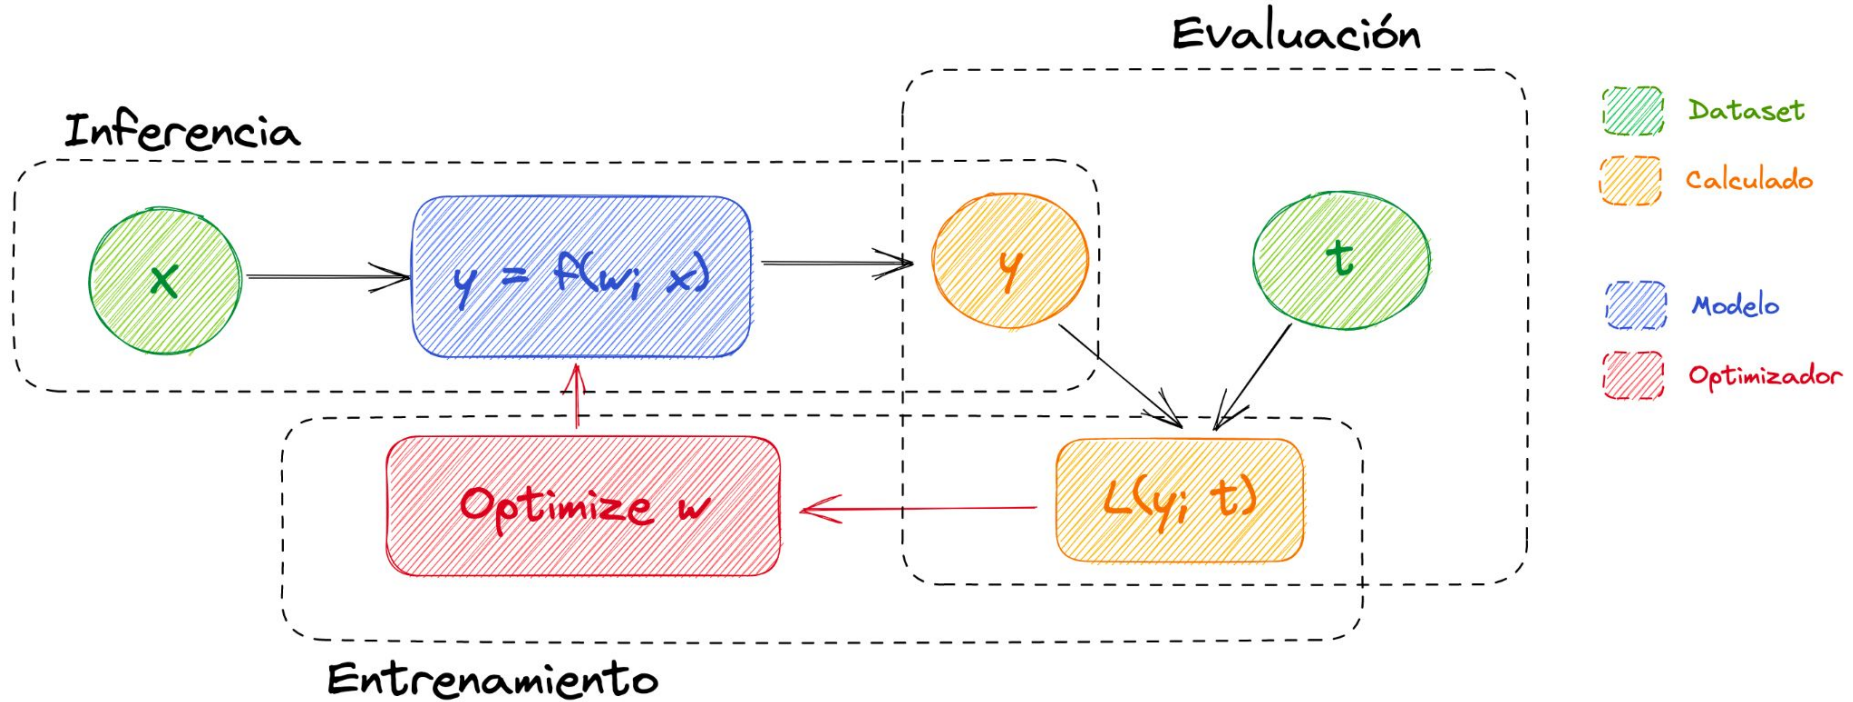
# Repaso: Optimizador



# Repaso:

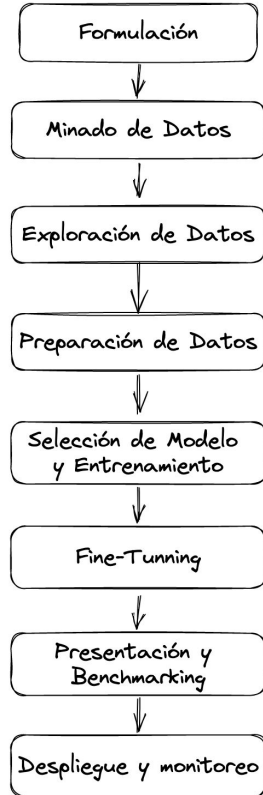


# Repaso: Inferencia vs Entrenamiento

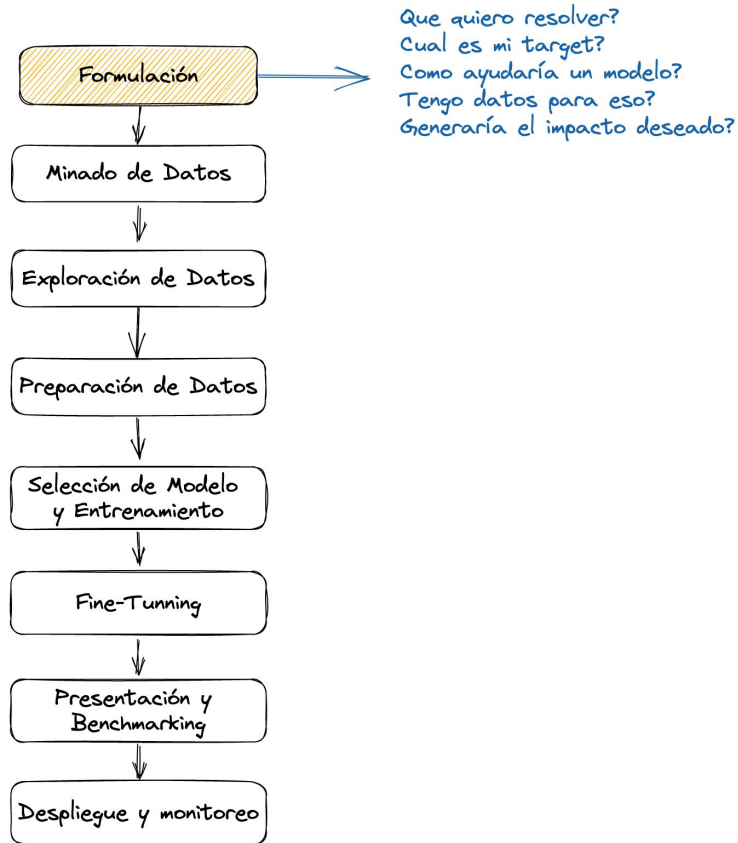




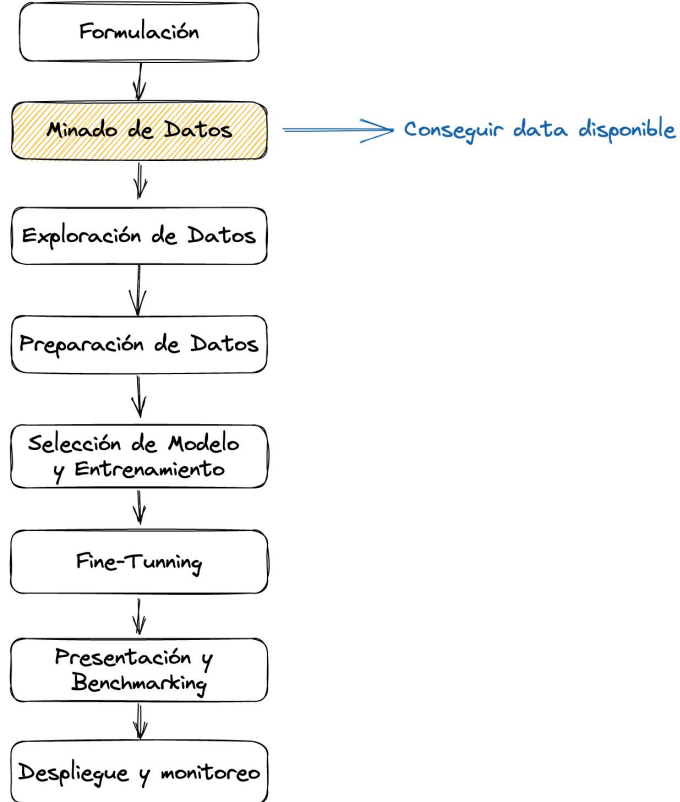
# ML End to End



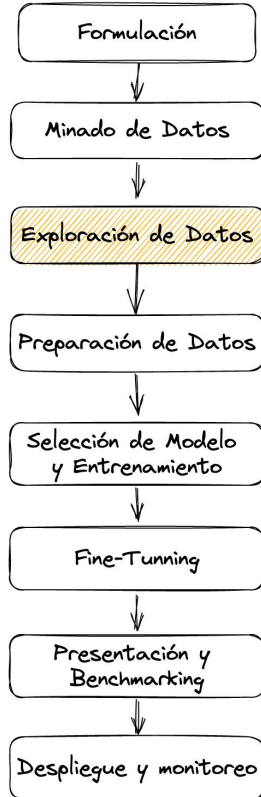
# ML End to End



# ML End to End

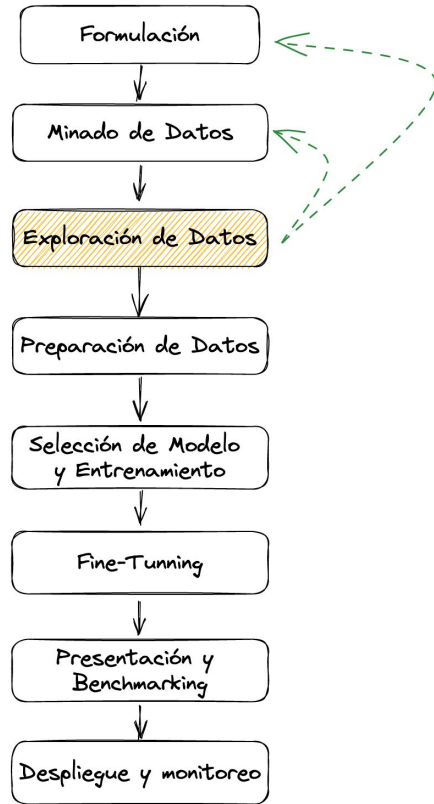


# ML End to End

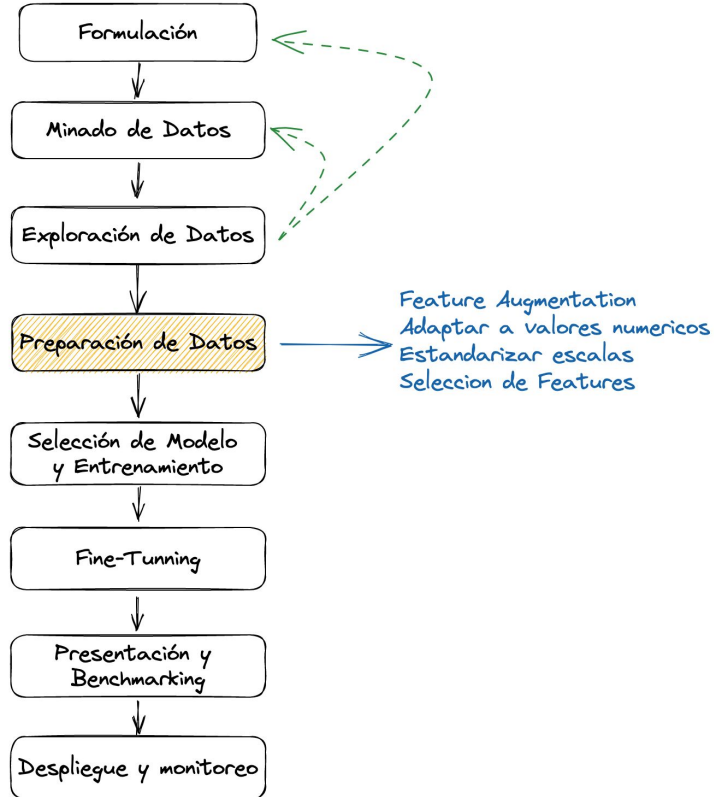


Como son los datos que tengo?  
Como se correlacionan las variables con mi target?  
y entre si?  
Estan limpios los datos? Tienen algun bias conocido?

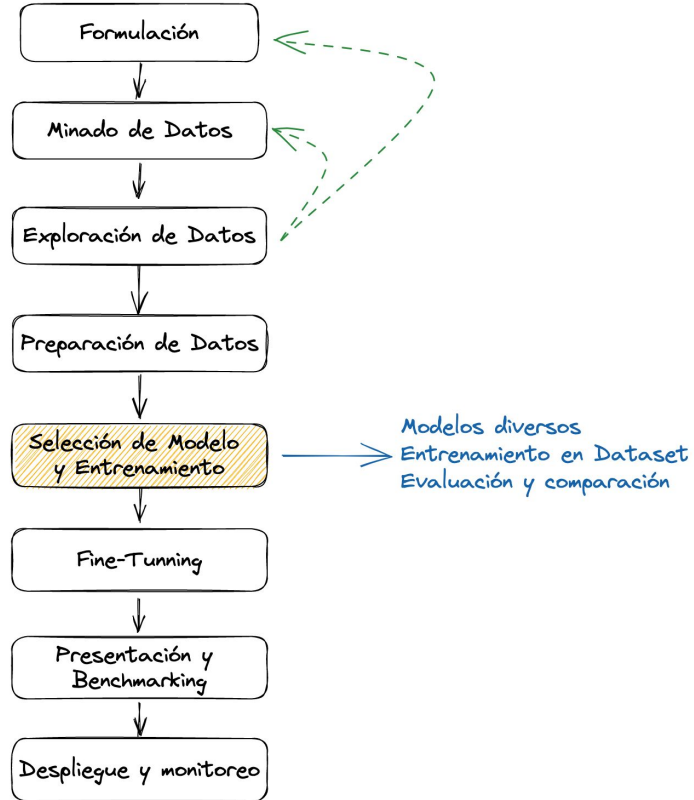
# ML End to End



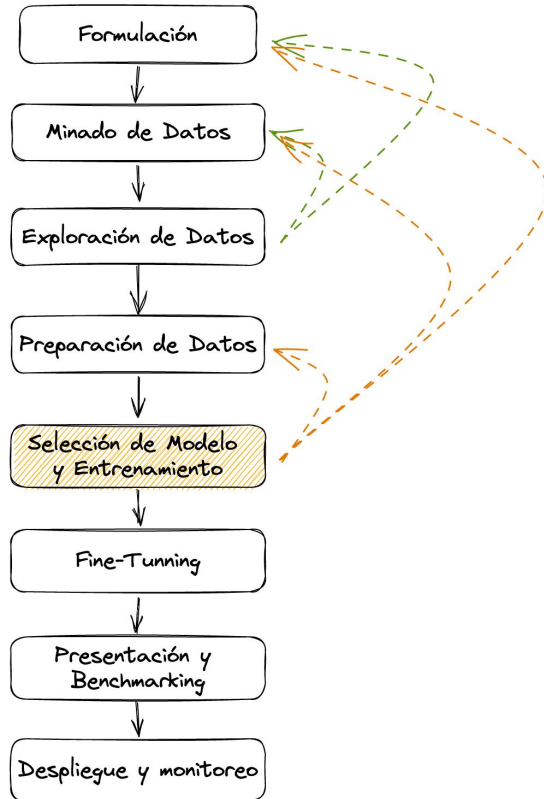
# ML End to End



# ML End to End

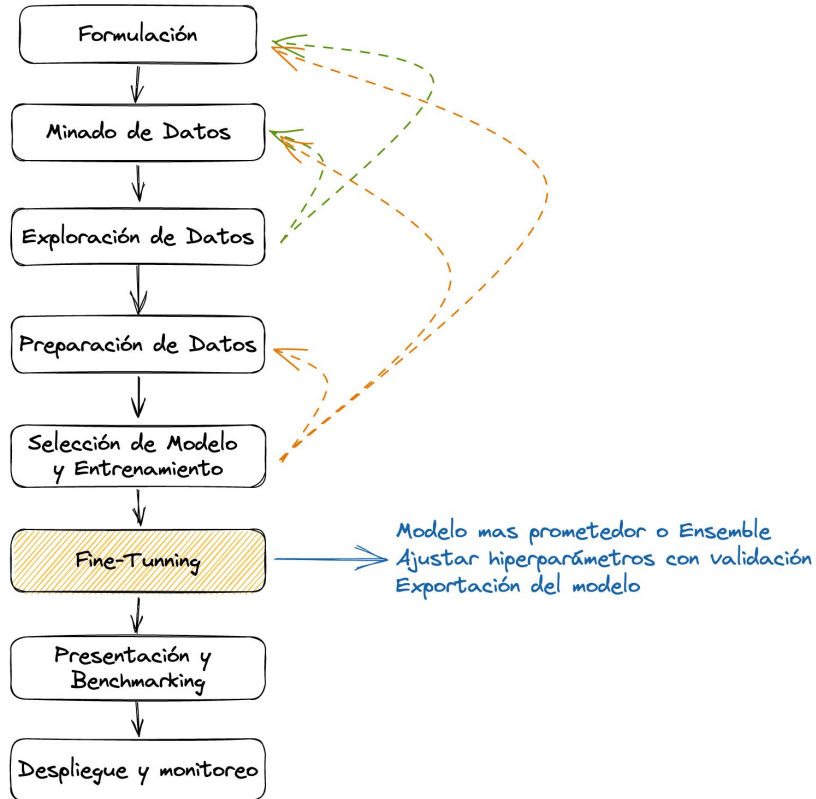


# ML End to End

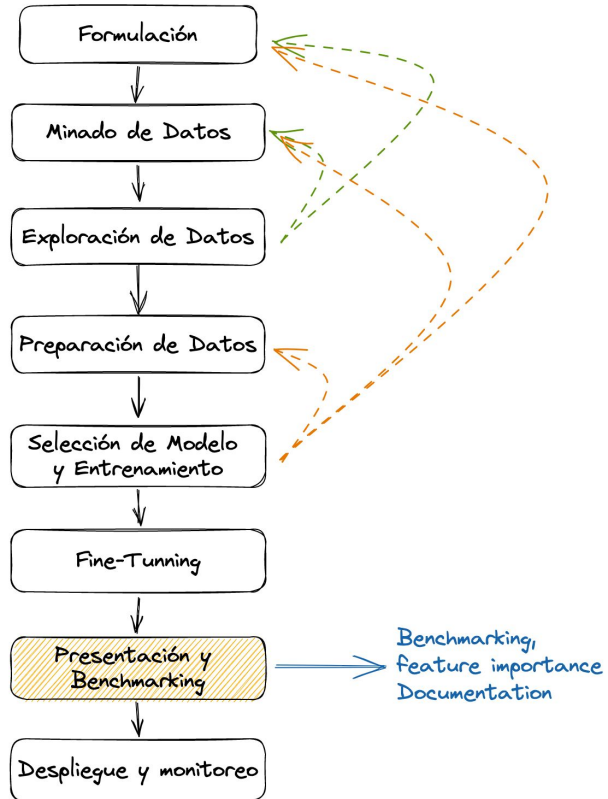




# ML End to End



# ML End to End



# ML End to End

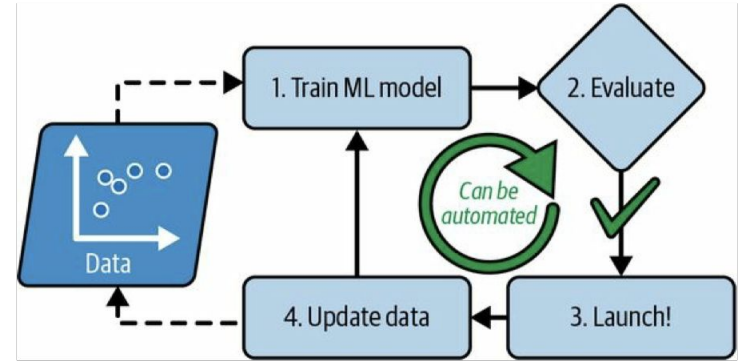
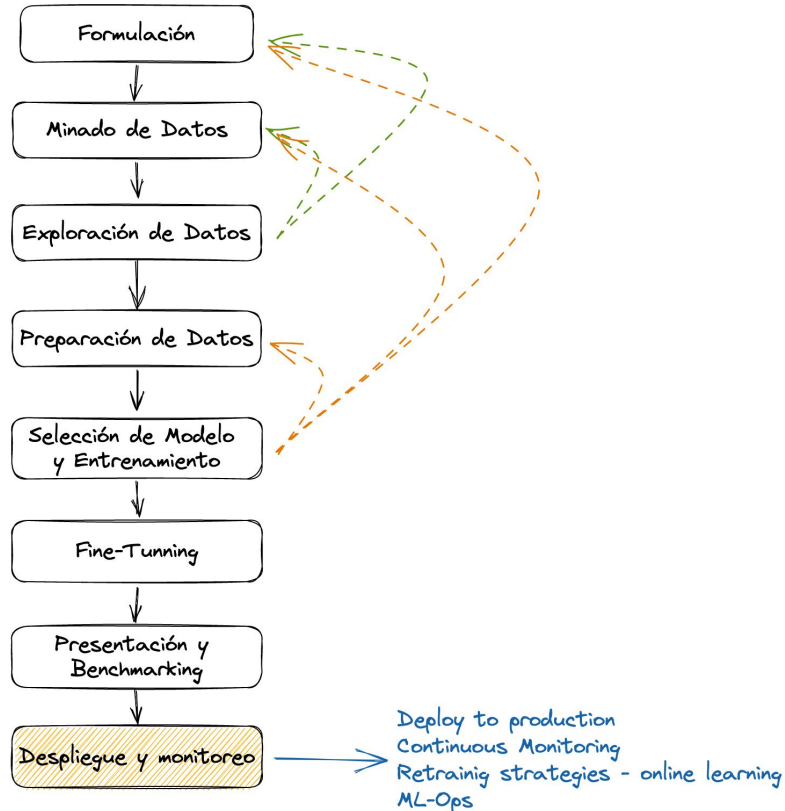


Figure 1-3. Automatically adapting to change

# ML End to End

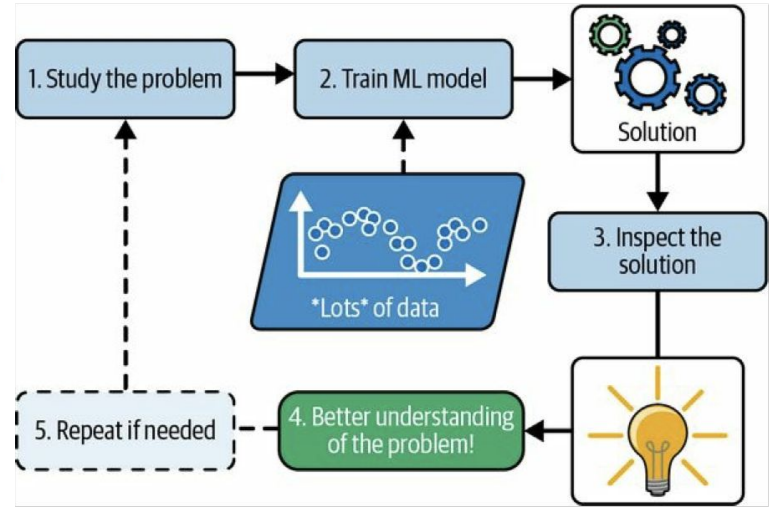
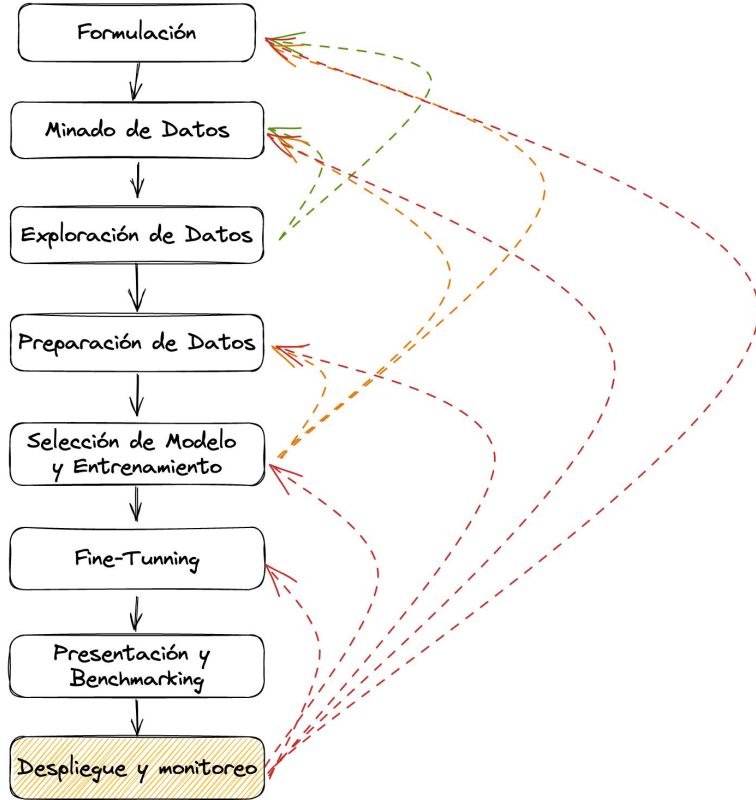



Figure 1-4. Machine learning can help humans learn

# Regresión: Modelo Lineal

- Ecuación de una recta:

$$y = ax + b$$



# Regresión: Modelo Lineal

- Ecuación de una recta:


$$y = ax + b$$

ind. var  
*a.k.a. output*

Pendiente  
*a.k.a. peso*

dep. var  
*a.k.a input*

Ordenada al origen  
*a.k.a. bias*



# Regresión: Modelo Lineal

- Ecuación de una recta:

$$y = ax + b$$

ind. var  
*a.k.a. output*


Pendiente  
*a.k.a. peso*

dep. var  
*a.k.a input*

Ordenada al origen  
*a.k.a. bias*

$$y = w_1x + w_0$$

pesos



# Regresión: Modelo Lineal

- Una sola variable: Un solo feature

$$y = w_1x + w_0$$

- Multivariable: Muchas features

$$y = w_0 + w_1x_1 + \dots + w_Nx_N$$

$$= \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_N \end{pmatrix} (1 \quad x_1 \quad \dots \quad x_N)$$



# Regresión: Modelo Lineal

- Multivariable:  
Muchas features  
Un solo sample


$$y = \begin{pmatrix} w_0 \\ w_2 \\ \vdots \\ w_N \end{pmatrix} (1 \quad x_1 \quad x_2 \quad \dots \quad x_N) = \vec{w} \cdot \vec{x}$$

- Multivariable:  
Muchas features  
Muchos Samples

$$\begin{aligned} \vec{y} = \begin{pmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(M)} \end{pmatrix} &= \begin{pmatrix} w_0 \\ w_2 \\ \vdots \\ w_N \end{pmatrix} \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_N^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_N^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(M)} & x_2^{(M)} & \dots & x_N^{(M)} \end{pmatrix} \\ &= \vec{w} \cdot \bar{X} \end{aligned}$$

# Regresión: Modelo Lineal

- Modelo lineal



- ¿Qué más hace falta?

# Regresión Lineal: Función de Pérdida/Error

- Error cuadrático 
$$\begin{aligned} e(y^{(i)}; t^{(i)}) &= (y^{(i)} - t^{(i)})^2 \\ &= (y^{(i)}(\vec{w}; \vec{x}^{(i)}) - t^{(i)})^2 \end{aligned}$$

# Regresión Lineal: Función de Pérdida/Error

- Error cuadrático 
$$\begin{aligned} e(y^{(i)}; t^{(i)}) &= (y^{(i)} - t^{(i)})^2 \\ &= (y^{(i)}(\vec{w}; \vec{x}^{(i)}) - t^{(i)})^2 \end{aligned}$$
- Error cuadrático medio (MSE) 
$$\begin{aligned} MSE(\vec{y}; \vec{t}) &= \frac{1}{M} \sum_{i=1}^M (y^{(i)} - t^{(i)})^2 \\ &= \frac{1}{M} \|\vec{y} - \vec{t}\|^2 \\ &= MSE(\bar{X}, \vec{t}; \vec{w}) \end{aligned}$$

# Regresión Lineal: Optimizador

- Minimizar el error:  
Queremos encontrar los pesos que minimizan el la hiper-paraboloide

$$MSE(\bar{X}, \vec{t}; \vec{w}) = \frac{1}{M} \left| \vec{w} \cdot \bar{X} - \vec{t} \right|^2$$

- Gradient Descent:  
Nos podemos mover en la dirección de máxima variación del gradiente

$$\nabla_{\vec{w}} MSE = \frac{2}{M} (\vec{w} \cdot \bar{X} - \vec{t}) \cdot \bar{X}^t$$

- Solver: En este caso hay una solución algebraica exacta al gradiente nulo (mínimo).

# Regresión Lineal

- Modelo

$$\vec{y} = \vec{w} \cdot \bar{X}$$

- Función de Pérdida MSE

$$MSE(\bar{X}, \vec{t}; \vec{w}) = \frac{1}{M} \left| \vec{w} \cdot \bar{X} - \vec{t} \right|^2$$

- Optimizador:

- Solver algebraico (exacto)
- ó Descenso por Gradiente (iterativo)

$$\nabla_{\vec{w}} MSE = \frac{2}{M} (\vec{w} \cdot \bar{X} - \vec{t}) \cdot \bar{X}^t$$