


IAA-2023c1

Clase 2: ML End to End & Regresión Lineal

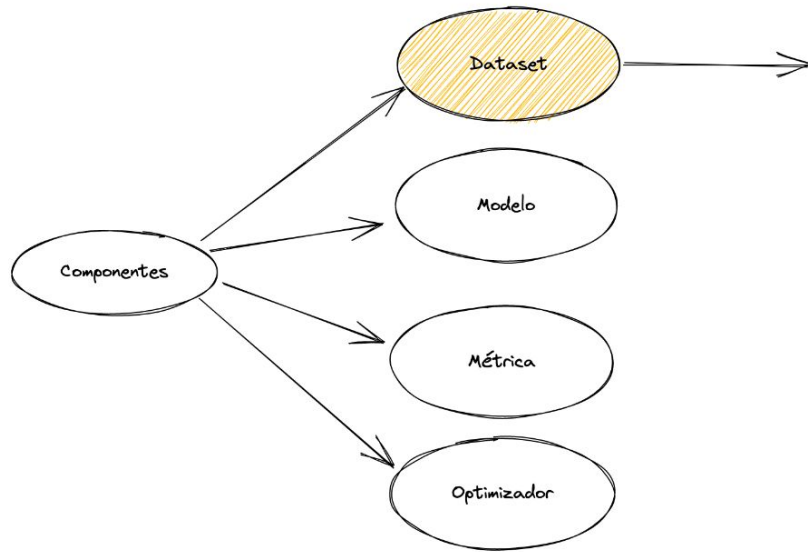


UNSAM
UNIVERSIDAD
NACIONAL DE
SAN MARTÍN


Repaso: Componentes



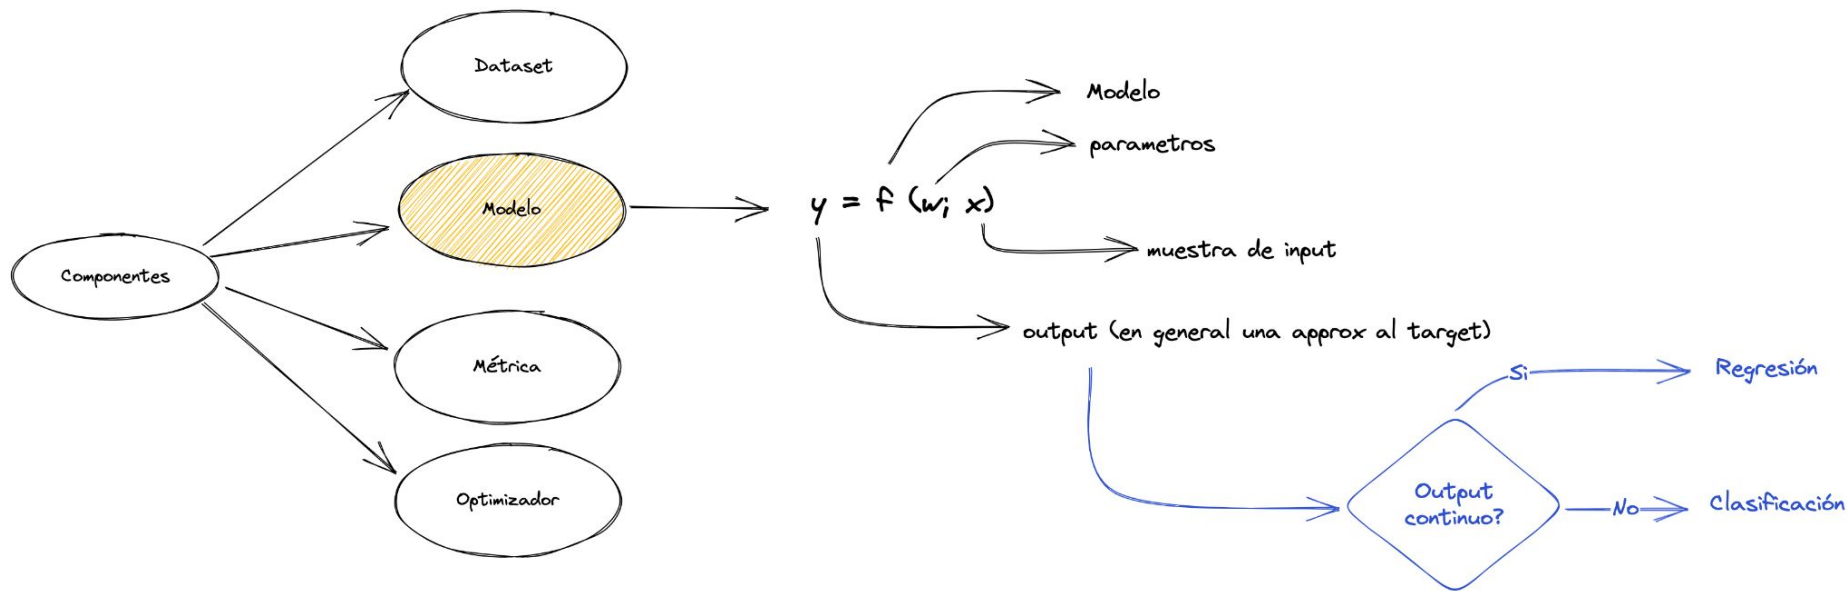
Repaso: Supervisado vs No Supervisado



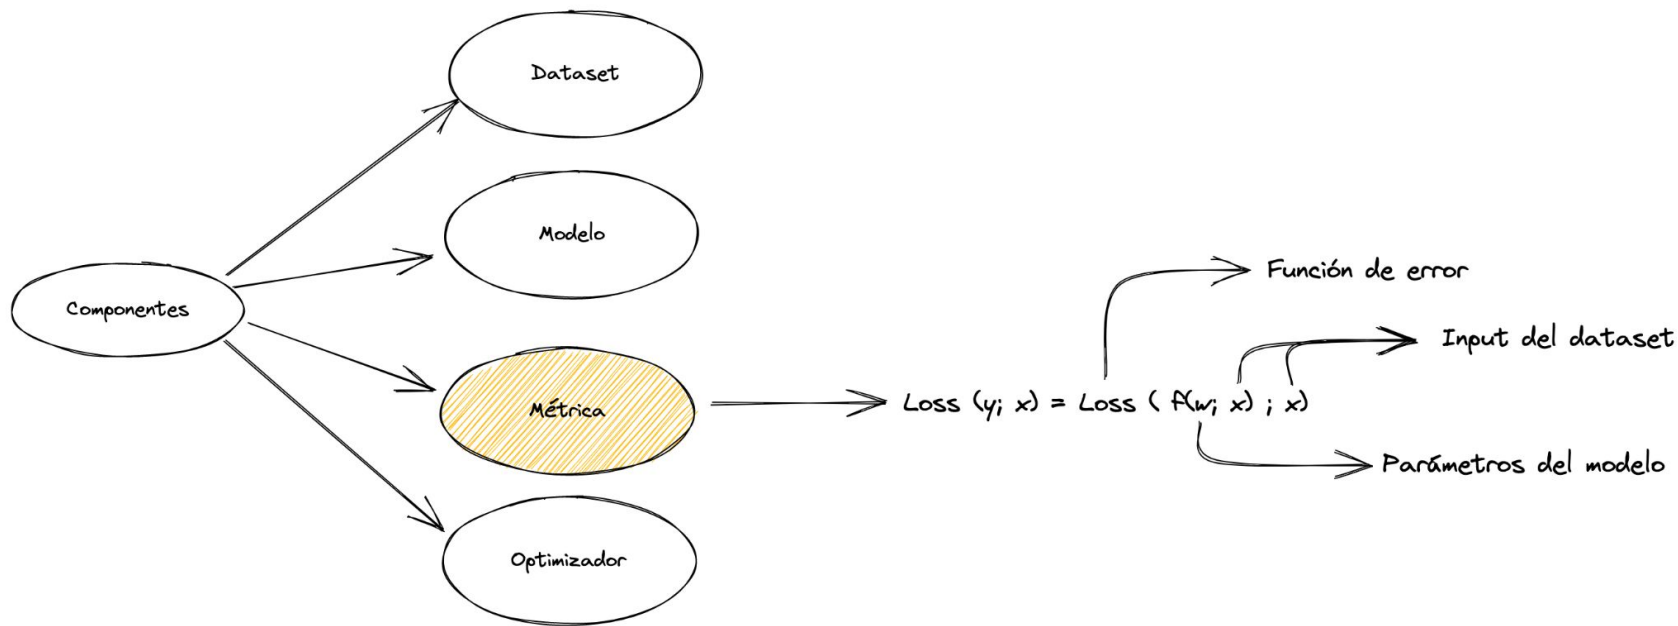
	feature 1	feature 2	...	feature M	target
muestra 1	"Matriz de diseño"				
muestra 2					
muestra 3					
...					
muestra N					



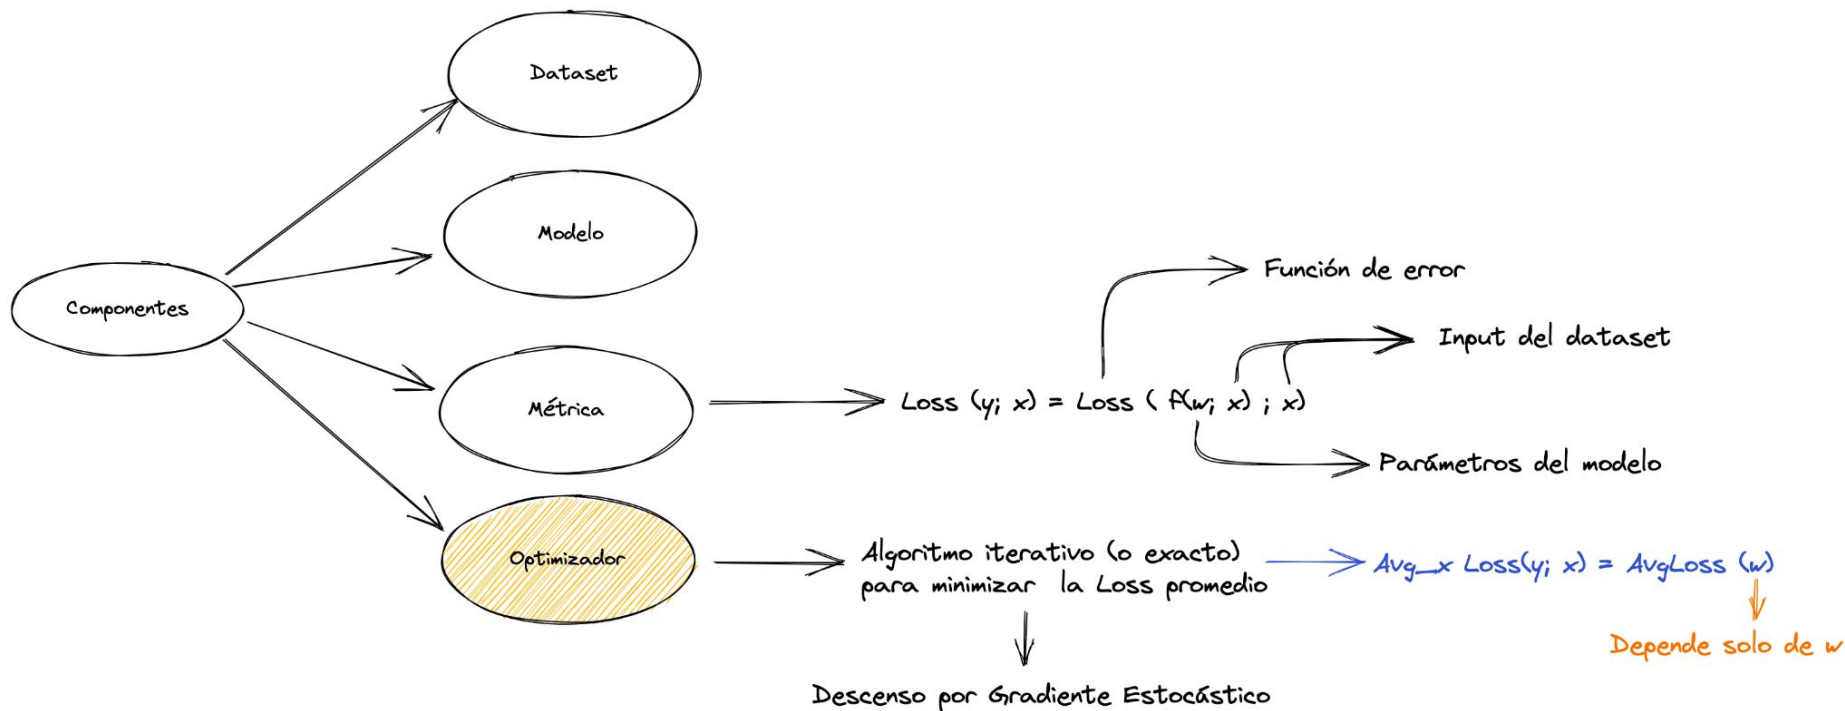
Repaso: Regresión vs Clasificación



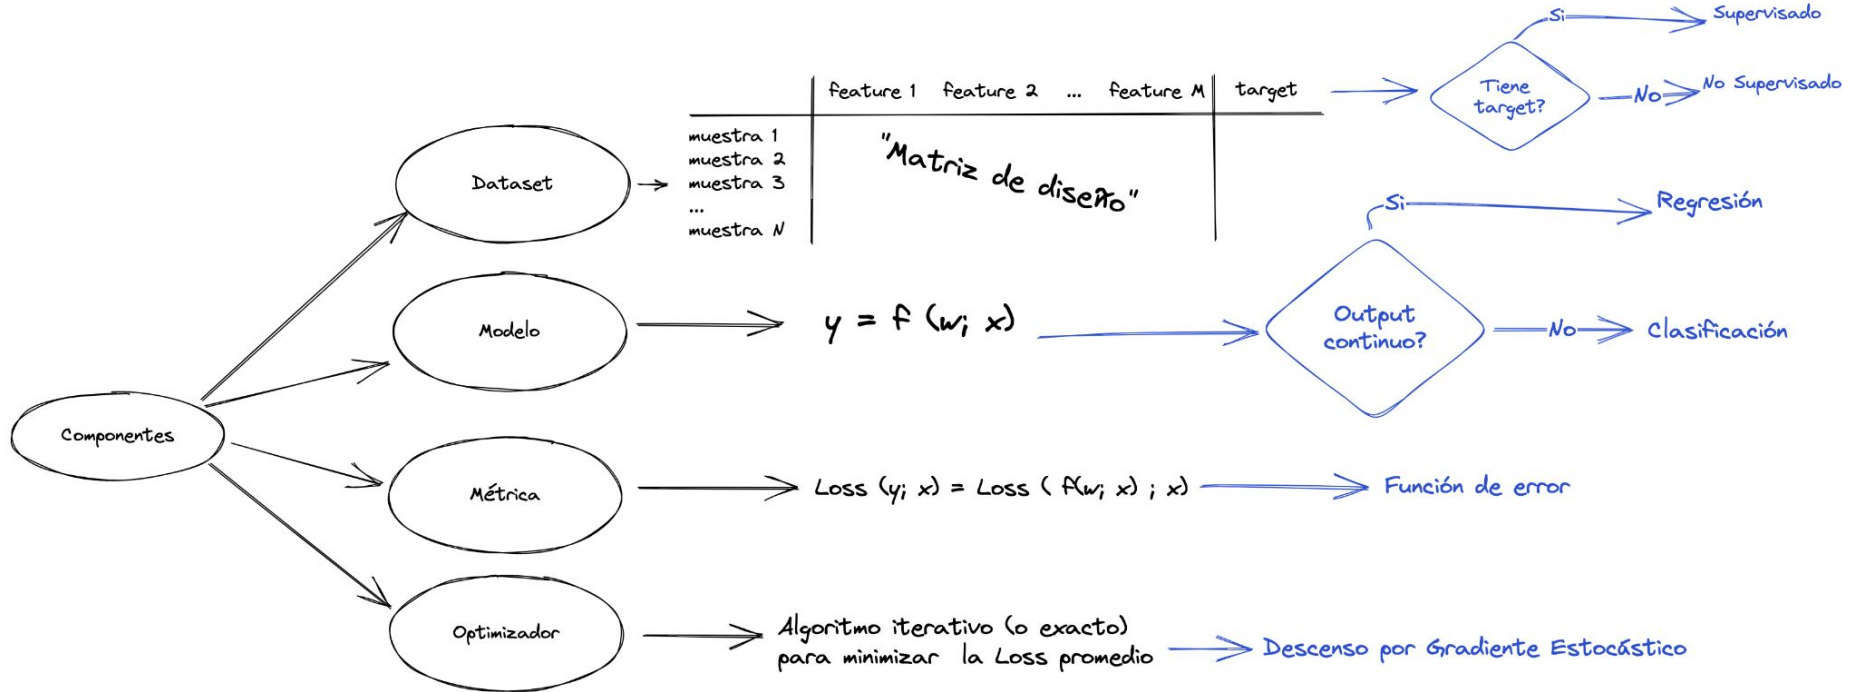
Repaso: Métrica y Función de Error / Pérdida



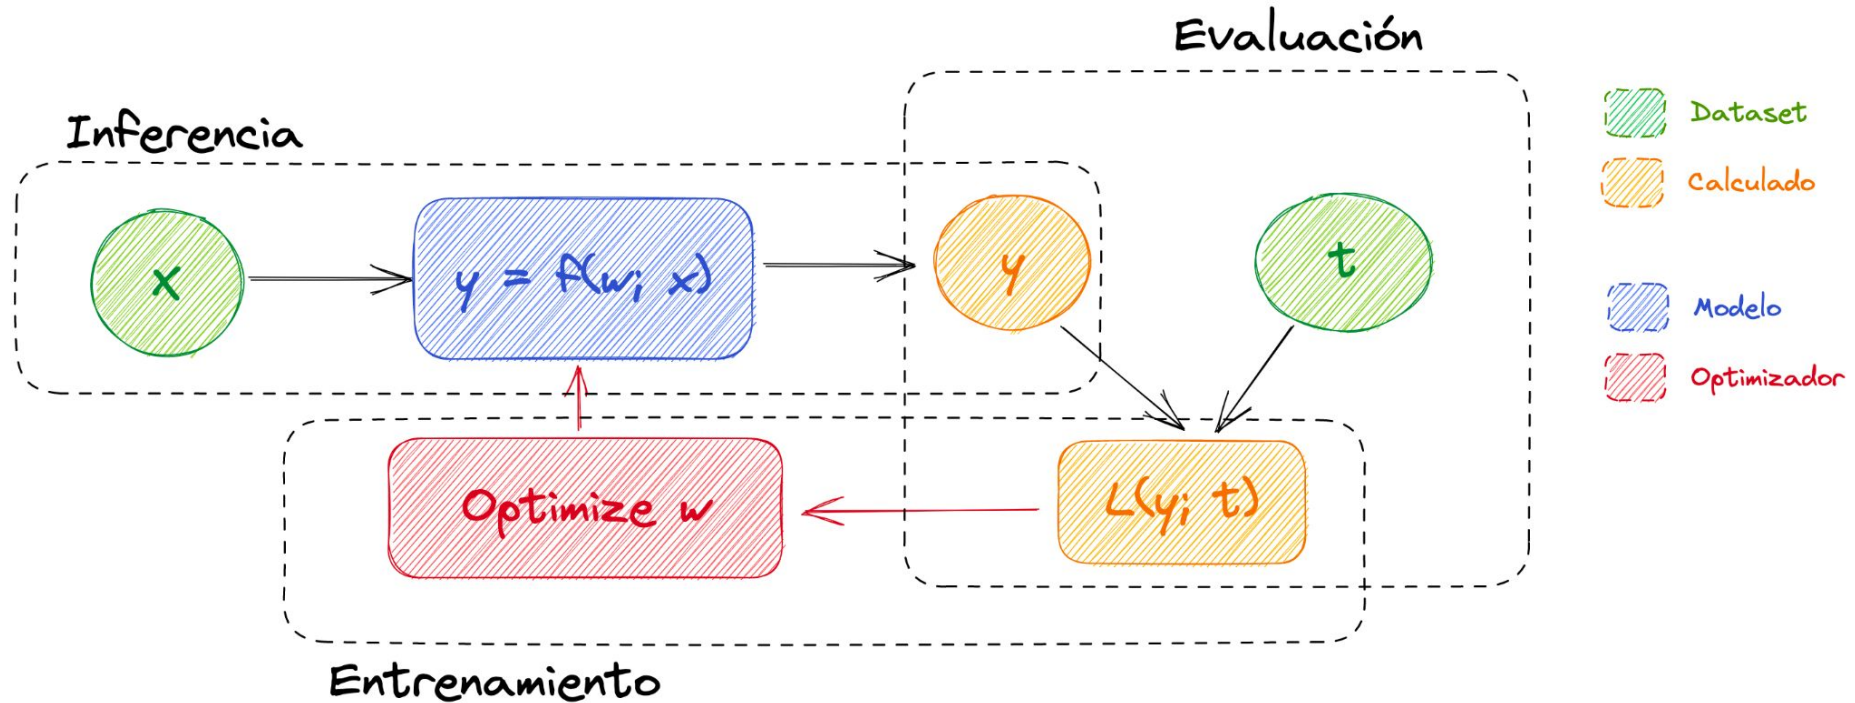
Repaso: Optimizador



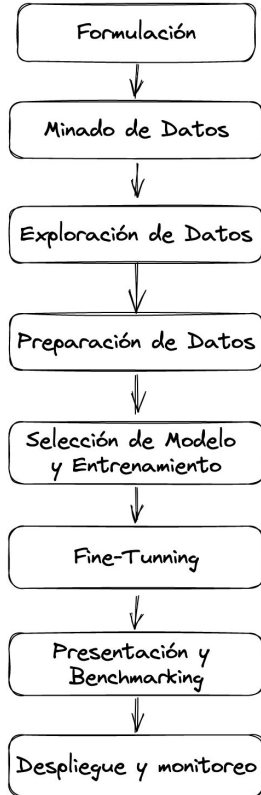
Repaso:



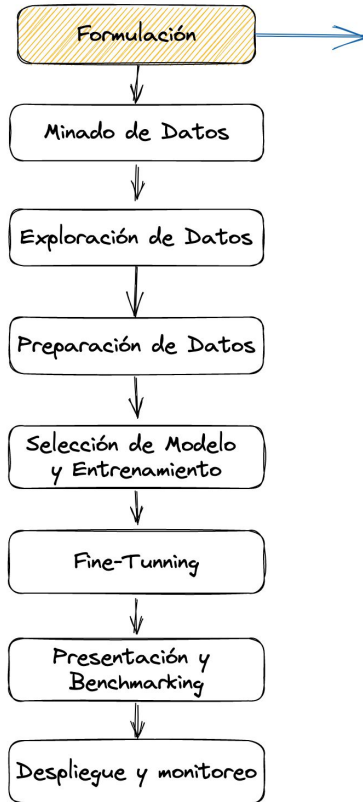
Repaso: Inferencia vs Entrenamiento



ML End to End

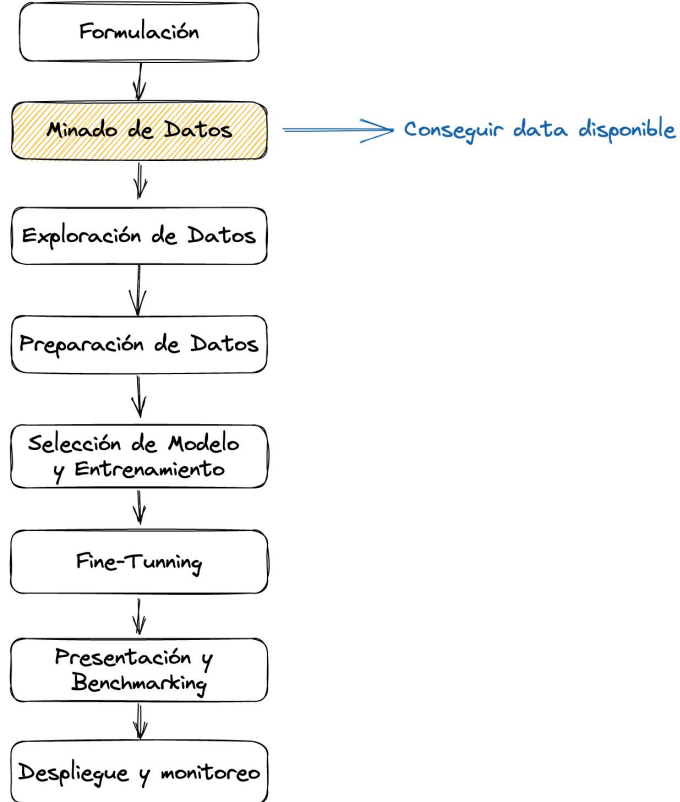


ML End to End

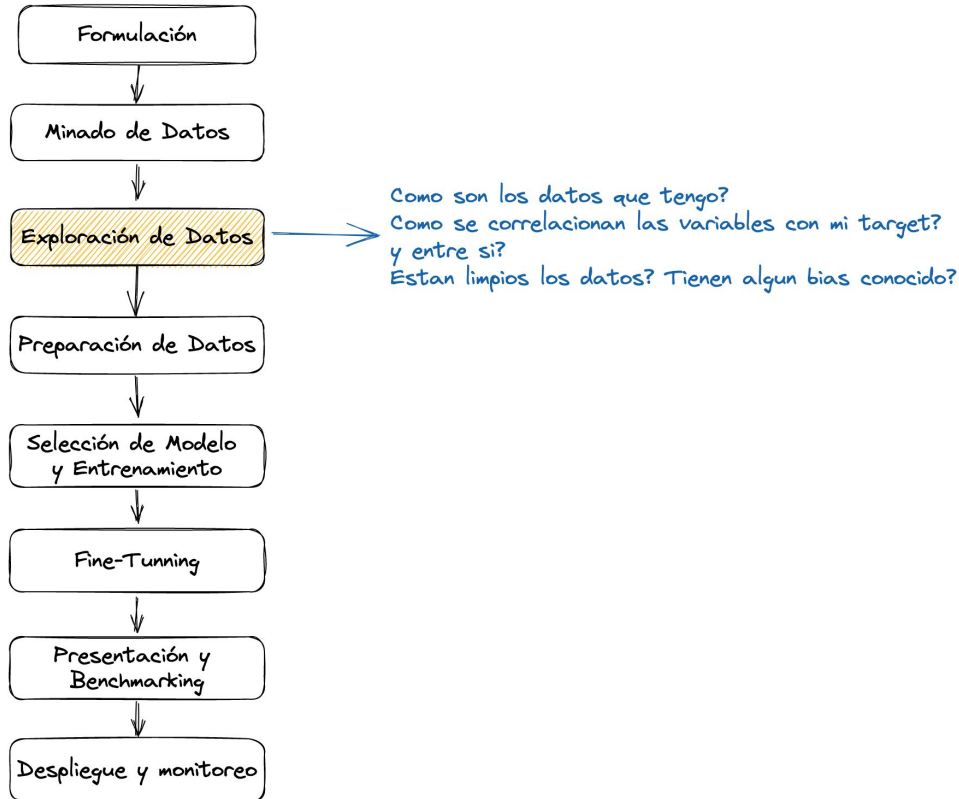


Que quiero resolver?
Cual es mi target?
Como ayudaría un modelo?
Tengo datos para eso?
Generaría el impacto deseado?

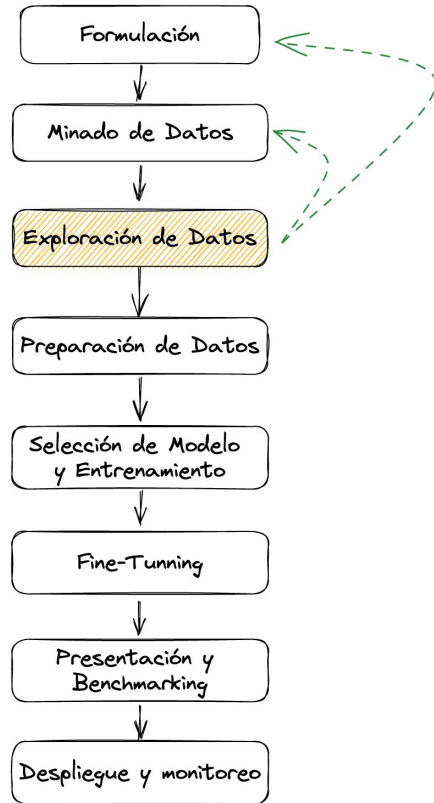
ML End to End



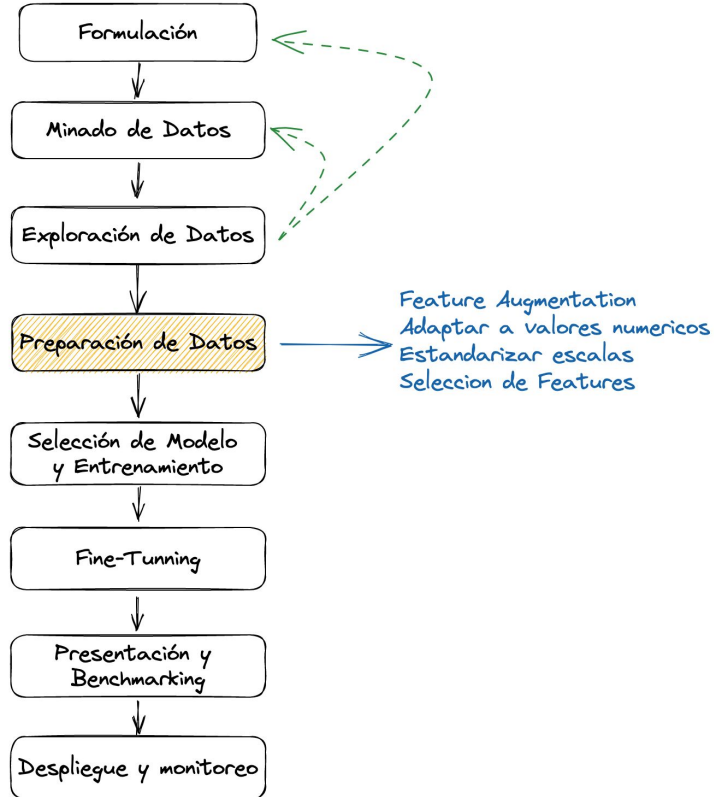
ML End to End



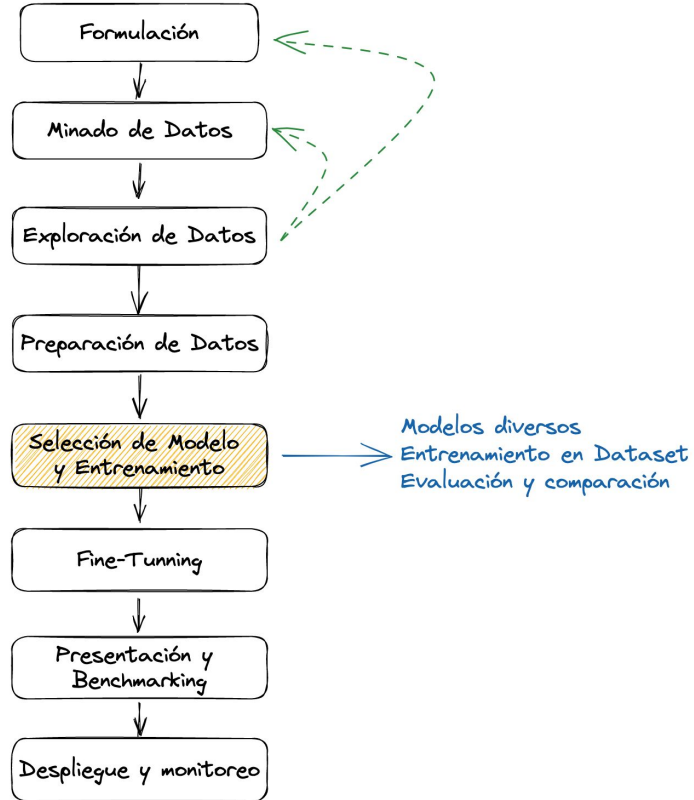
ML End to End



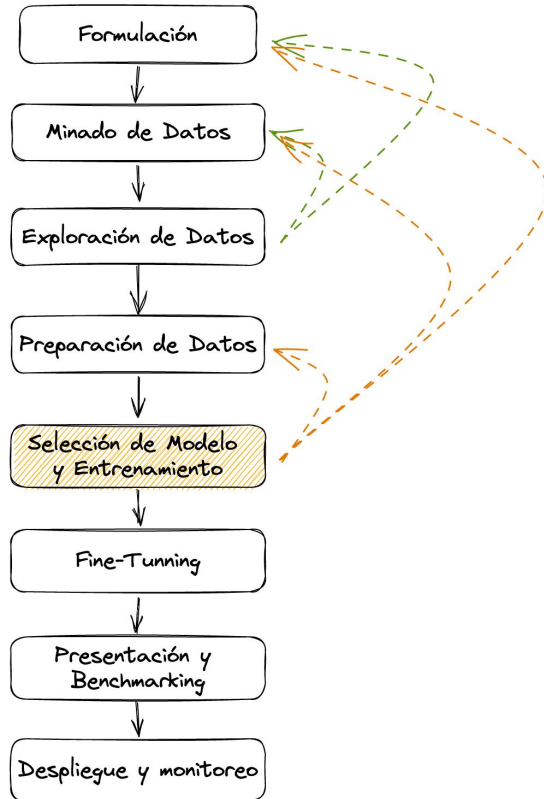
ML End to End



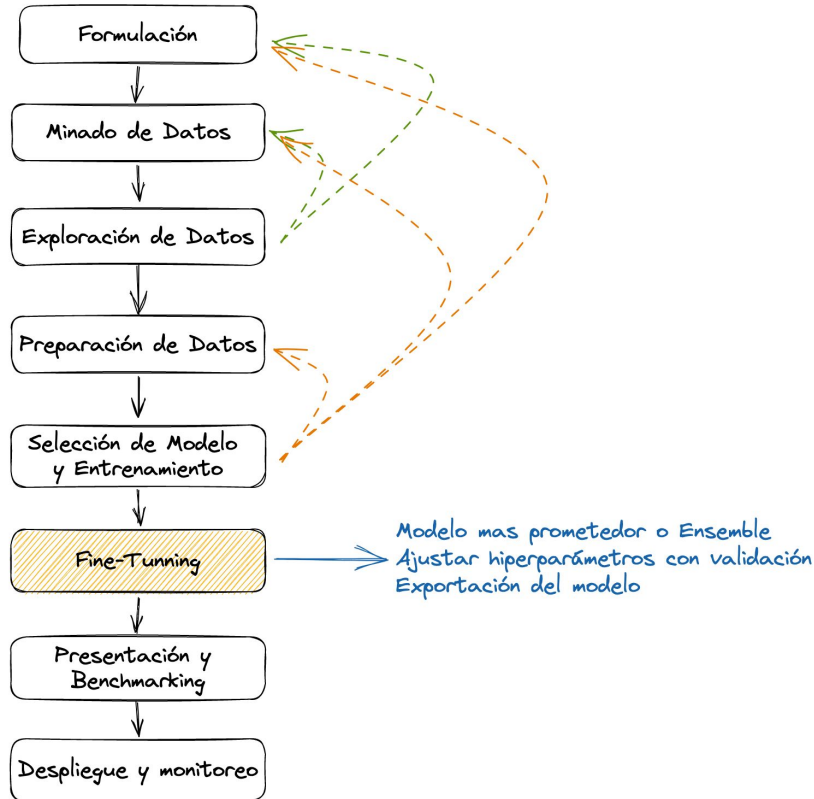
ML End to End



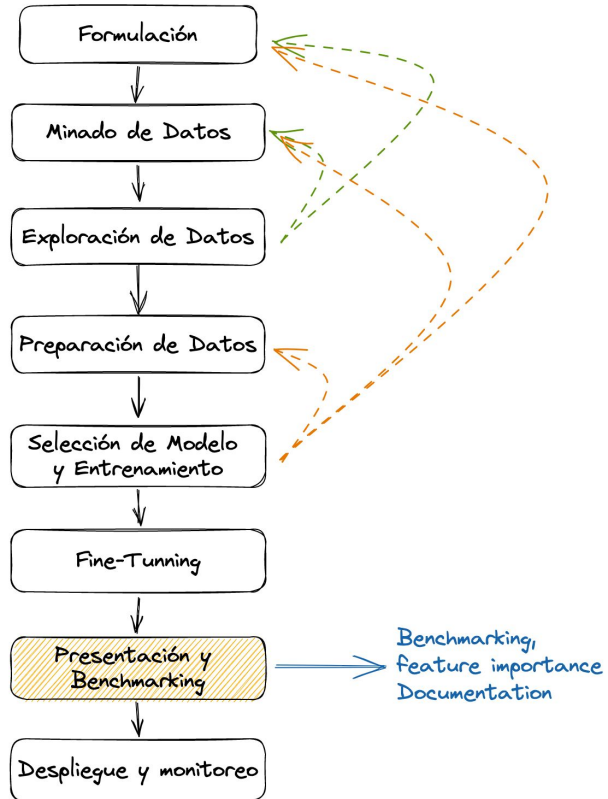
ML End to End



ML End to End



ML End to End



ML End to End

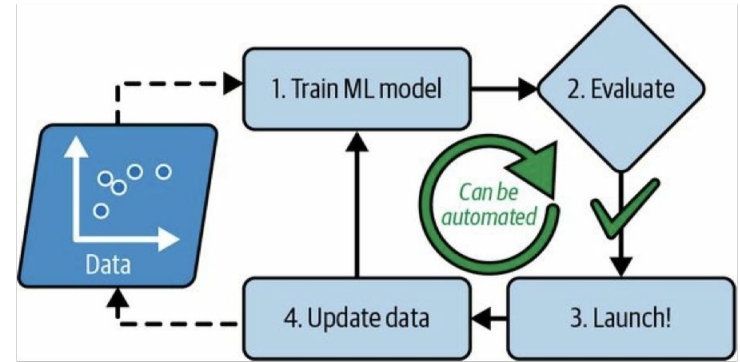
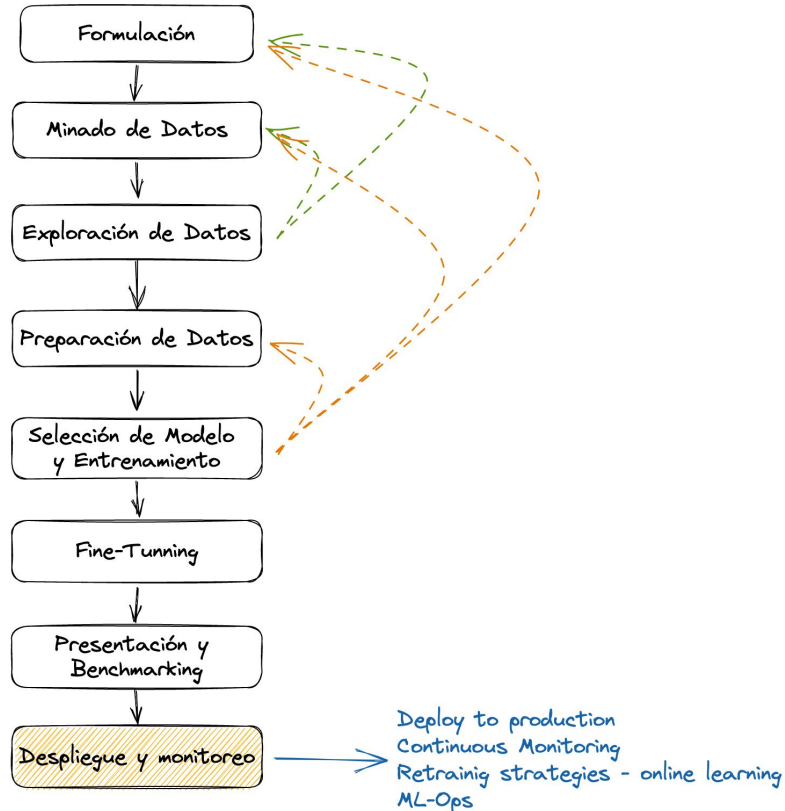


Figure 1-3. Automatically adapting to change

ML End to End

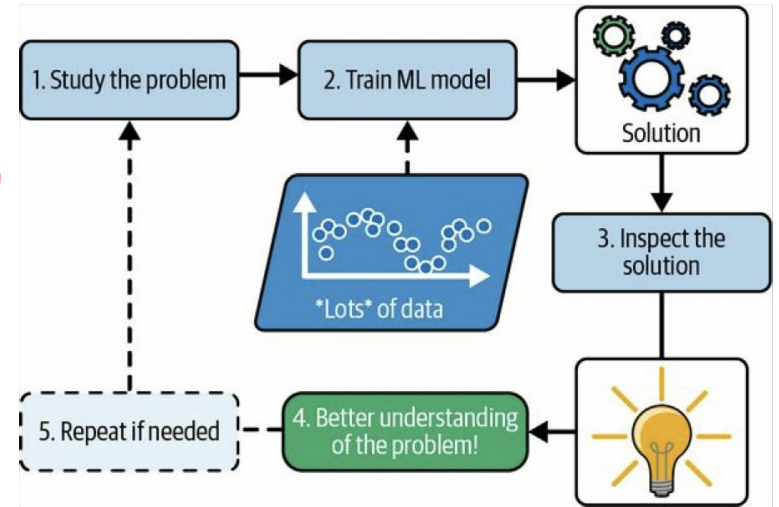
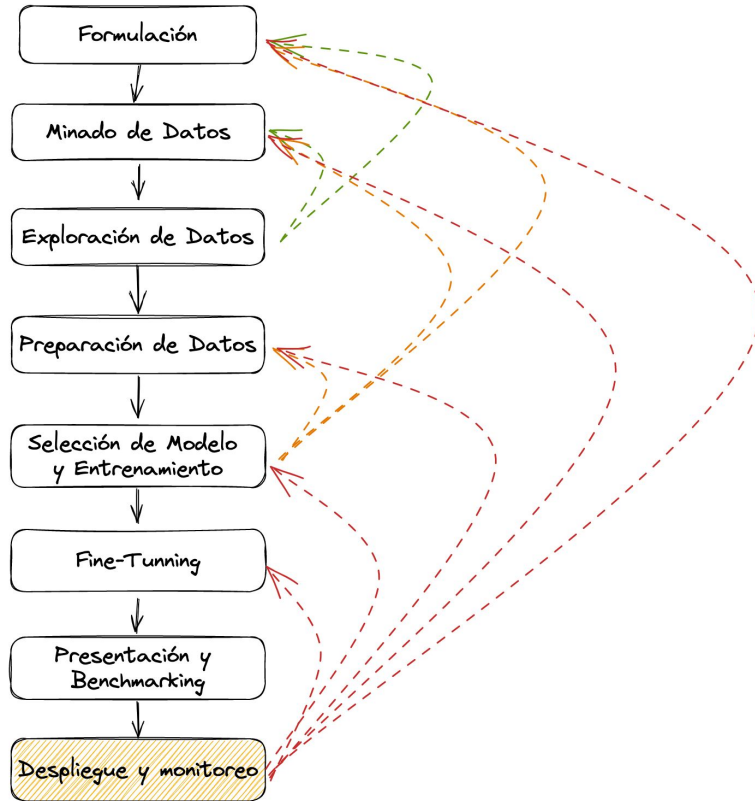



Figure 1-4. Machine learning can help humans learn

Regresión: Modelo Lineal

- Ecuación de una recta:

$$y = ax + b$$



Regresión: Modelo Lineal

- Ecuación de una recta:


$$y = ax + b$$

ind. var
a.k.a. output

Pendiente
a.k.a. peso

dep. var
a.k.a input

Ordenada al origen
a.k.a. bias



Regresión: Modelo Lineal

- Ecuación de una recta:

$$y = ax + b$$

ind. var
a.k.a. output


dep. var
a.k.a input

Pendiente
a.k.a. peso

Ordenada al origen
a.k.a. bias

$$y = w_1x + w_0$$

pesos



Regresión: Modelo Lineal

- Una sola variable: Un solo feature

$$y = w_1x + w_0$$

- Multivariable: Muchas features

$$y = w_0 + w_1x_1 + \dots + w_Nx_N$$

$$= \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_N \end{pmatrix} (1 \quad x_1 \quad \dots \quad x_N)$$

Regresión: Modelo Lineal

- Multivariable:
Muchas features
Un solo sample


$$y = \begin{pmatrix} w_0 \\ w_2 \\ \vdots \\ w_N \end{pmatrix} (1 \quad x_1 \quad x_2 \quad \dots \quad x_N) = \vec{w} \cdot \vec{x}$$

- Multivariable:
Muchas features
Muchos Samples

$$\begin{aligned} \vec{y} = \begin{pmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(M)} \end{pmatrix} &= \begin{pmatrix} w_0 \\ w_2 \\ \vdots \\ w_N \end{pmatrix} \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_N^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_N^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(M)} & x_2^{(M)} & \dots & x_N^{(M)} \end{pmatrix} \\ &= \vec{w} \cdot \bar{X} \end{aligned}$$

Regresión: Modelo Lineal

- Modelo lineal



- ¿Qué más hace falta?

Regresión Lineal: Función de Pérdida/Error

- Error cuadrático
$$\begin{aligned} e(y^{(i)}; t^{(i)}) &= (y^{(i)} - t^{(i)})^2 \\ &= (y^{(i)}(\vec{w}; \vec{x}^{(i)}) - t^{(i)})^2 \end{aligned}$$

Regresión Lineal: Función de Pérdida/Error

- Error cuadrático $e(y^{(i)}; t^{(i)}) = (y^{(i)} - t^{(i)})^2$
 $= (y^{(i)}(\vec{w}; \vec{x}^{(i)}) - t^{(i)})^2$
- Error cuadrático medio (MSE) $MSE(\vec{y}; \vec{t}) = \frac{1}{N} \sum_{i=1}^N (y^{(i)} - t^{(i)})^2$
 $= \frac{1}{N} \|\vec{y} - \vec{t}\|^2$
 $= MSE(\bar{X}, \vec{t}; \vec{w})$

Regresión Lineal: Optimizador

- Minimizar el error:
Queremos encontrar los pesos que minimizan el la hiper-paraboloide

$$MSE(\bar{X}, \vec{t}; \vec{w}) = \frac{1}{N} \left| \vec{w} \cdot \bar{X} - \vec{t} \right|^2$$

- Gradient Descent:
Nos podemos mover en la dirección de máxima variación del gradiente

$$\nabla_{\vec{w}} MSE = \frac{2}{N} (\vec{w} \cdot \bar{X} - \vec{t}) \cdot \bar{X}^t$$

- Solver: En este caso hay una solución algebraica exacta al gradiente nulo (mínimo).

Regresión Lineal

- Modelo

$$\vec{y} = \vec{w} \cdot \bar{X}$$

- Función de Pérdida MSE

$$MSE(\bar{X}, \vec{t}; \vec{w}) = \frac{1}{N} \left| \vec{w} \cdot \bar{X} - \vec{t} \right|^2$$

- Optimizador:

- Solver algebraico (exacto)
- ó Descenso por Gradiente (iterativo)

$$\nabla_{\vec{w}} MSE = \frac{2}{N} (\vec{w} \cdot \bar{X} - \vec{t}) \cdot \bar{X}^t$$